Analyse d'expression génique dans la leucémie lymphoblastique aiguë pédiatrique hyperdiploïde par microarrays

Alexandre Corbelli
Sciper 343100

Juillet 2025

1 Introduction

Dans cette analyse, nous étudions les profils d'expression génique obtenus à partir de puces Affymetrix afin d'identifier les gènes différemment exprimés entre des cas de leucémies aiguës lymphoblastiques pédiatriques hyperdiploïdes avec 50 chromosomes, et un groupe de référence dit "normal". Ce groupe normal comprend des échantillons à caryotype normal, pseudodiploïde ou hyperdiploïde sans anomalie cytogénétique récurrente connue (telles que TEL-AML1, BCR-ABL, ou MLL) [1]. Ces cas ne présentent donc pas de réarrangements chromosomiques spécifiques permettant une classification dans les sous-types moléculaires bien définis. Nous utilisons la méthode de normalisation RMA pour extraire les valeurs d'expression, puis appliquons un modèle linéaire avec modération bayésienne empirique (via le package limma) pour tester la différence d'expression génique entre les deux groupes. L'analyse inclut également des étapes de contrôle qualité, la visualisation des données par clustering et représentations graphiques, ainsi qu'un classement des gènes les plus significativement différemment exprimés. Cette comparaison vise à mettre en évidence les particularités du sous-type hyperdiploïde et à les distinguer des cas sans anomalie cytogénétique récurrente.

2 Analyse de la qualité des données

Pour cette expérience, nous considérons les données de départ suivantes : 23 puces microarrays correspondent aux échantillons hyperdiploïdes et 19 aux échantillons normaux, soit un total de 42 échantillons.
Chaque puce contient des valeurs d'expression pour 12 625 gènes. Afin de déterminer si certaines puces sont défectueuses ou inadaptées, nous utilisons deux graphiques : le RLE (Relative Log Expression) et le NUSE (Normalized Unscaled Standard Errors). Les deux graphiques de la figure 1 présentent ces résultats.

Du point de vue du RLE, nous observons que les puces hyperdiploïdes H23 et H28 ont une médiane assez éloignée de zéro. Parmi les puces normales, les puces N15 et N16 présentent également une médiane éloignée de zéro.

Concernant le graphique NUSE, seule la puce H28 affiche une valeur d'erreur standard supérieure à 1.05.

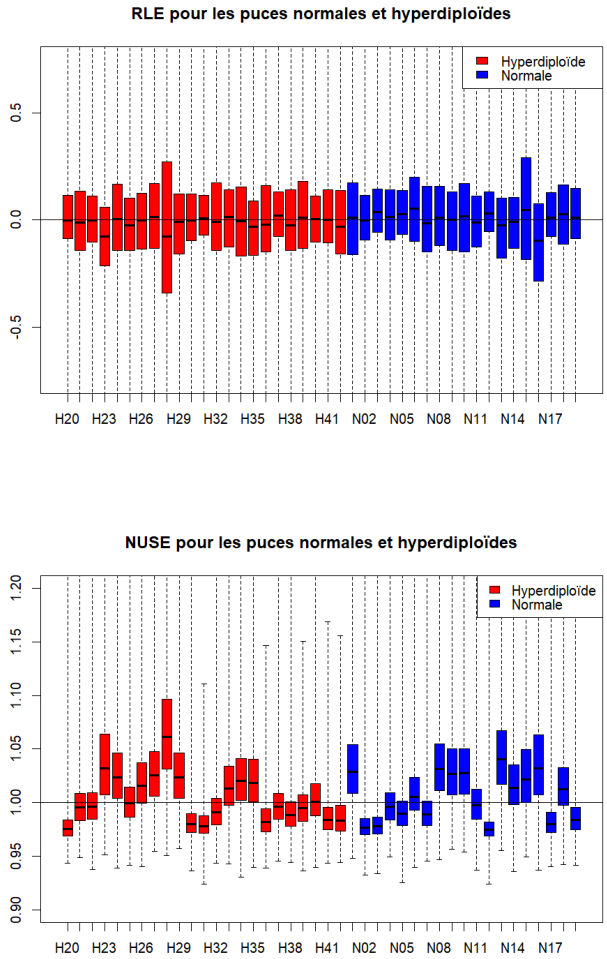


Figure 1: Évaluation de la qualité des puces microarrays : RLE et NUSE pour les échantillons hyperdiploïdes (en rouge) et normaux (en bleu).

À partir de ces deux graphiques, nous avons décidé d'exclure la puce H28, qui est la seule à présenter à la fois une erreur standard élevée et une médiane RLE notablement décalée par rapport à zéro.

3 Normalisation

L'expression des gènes est obtenue à l'aide de la méthode RMA (Robust Multi-Array Average). RMA fonctionne uniquement sur les sondes *Perfect Match* (PM) des puces Affymetrix. Elle commence par une correction de bruit de fond afin de réduire le bruit et le signal non spécifique dans les sondes PM. Ensuite, elle applique une normalisation par quantiles afin d'harmoniser les distributions d'intensité des sondes entre toutes les puces, éliminant ainsi les différences artificielles. Enfin, elle réalise une étape de synthèse (summarization) à l'aide d'un modèle robuste appelé *median polish*, qui combine les différentes sondes associées à un même gène en une seule valeur d'expression, transformée en log2.

La normalisation par quantiles fonctionne de la manière suivante : elle aligne les distributions d'intensité de toutes les puces en calculant, pour chaque quantile, la moyenne des

quantiles correspondants entre toutes les puces, et en l'utilisant comme valeur normalisée commune.

L'étape de synthèse repose sur le modèle additif suivant :

$$y_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}$$

Où :

- y_{ij} est l'intensité normalisée et transformée en log pour la sonde j sur la puce i,
- μ est la médiane globale (l'intercept),
- α_i est l'effet de la puce (effet ligne),
- β_j est l'effet de la sonde (effet colonne),
- ε_{ij} est le terme résiduel.

L'algorithme *median polish* est une procédure itérative permettant d'ajuster ce modèle additif. Il fonctionne comme suit :

1. Initialiser la matrice $Y = [y_{ij}]$.
2. Pour chaque colonne :
    - Calculer la médiane de la colonne.
    - Soustraire cette médiane à chaque élément de la colonne.
    - Enregistrer la médiane comme une partie de l'effet colonne β_j.
3. Pour chaque ligne :
    - Calculer la médiane de la ligne.
    - Soustraire cette médiane à chaque élément de la ligne.
    - Enregistrer la médiane comme une partie de l'effet ligne α_i.
4. Répéter les étapes 2 et 3 jusqu'à ce que les modifications deviennent négligeables (convergence).

La Figure 2 ci-dessous, nous montre les effets de la normalisation par quantiles appliquée aux données d'expression. Avant normalisation (en haut), les distributions d'intensité varient considérablement entre les puces, avec des médianes et des étendues différentes. Après normalisation (en bas), les distributions sont alignées, avec des médianes et une dispersion très similaire entre les échantillons.

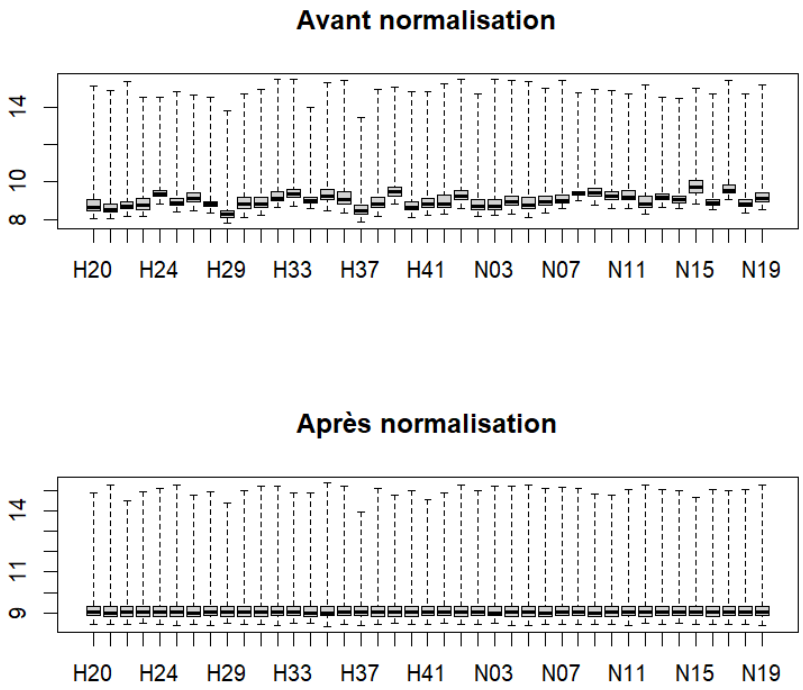


Figure 2: Boxplot des données avant et après la normalisation

4 Analyse de l'expression différentielle

Afin de déterminer les gènes différemment exprimés, nous avons considéré le modèle linéaire suivant, adapté à notre situation où seuls deux groupes sont pris en compte : hyperdiploïde et normal.

$$Y_i = \beta_0 + \beta_1 \delta_{x_{i2}=1} + \epsilon$$

Où :

1. Y_i est la valeur d'expression en log2 pour le i-ième gène.
2. β_0 est l'intercept, c'est-à-dire l'expression moyenne.
3. $\delta_{x_{i2}=1}$ est l'opérateur de Kronecker, qui vaut 1 si l'échantillon appartient au groupe normal, et 0 sinon.
4. β_1 représente le contraste entre les groupes hyperdiploïde et normal.
5. ϵ est le terme d'erreur, supposé suivre une loi $\mathcal{N}(0, \sigma^2)$.

Nous avons ensuite appliqué une modération bayésienne empirique au modèle ci-dessus afin d'améliorer l'estimation de la variance entre les gènes. L'analyse a révélé que : 712 gènes sont significativement sous-exprimés , 643 gènes sont significativement sur-exprimés et 11 270 gènes ne présentent pas de différence significative entre les deux groupes. Ces résultats suggèrent que plusieurs gènes présentent une expression différentielle significative entre les groupes hyperdiploïdes et normaux.

Dans une analyse d'expression différentielle impliquant des milliers de gènes, il est essentiel de corriger le risque de faux positifs dû à la multiplicité des tests. Nous avons utilisé une méthode de contrôle du taux de fausses découvertes (FDR, False Discovery Rate) pour ajuster les p-valeurs, en appliquant la méthode de Benjamini-Hochberg. Cette approche vise à limiter la proportion attendue de gènes faussement identifiés comme significatifs parmi ceux déclarés comme tels en utilisant la formule suivante :

$$p_i^* = \min_{k=i,i+1,..,m} [\min(\frac{m}{k} p_k, 1)]$$

avec p_j^* la j-ième p-valeur ajustée, m le nombre de p-valeur et p_j la j-ième p-valeur non ajustée.

4.1 Critère de sélection des gènes différemment exprimés

Les gènes ont été classés selon leurs p-valeurs ajustées. Pour déterminer les gènes significativement différenciés, nous avons utilisé un seuil de p-valeur ajustée $< 0{,}05$ qui, dans notre cas, détecte 1 355 gènes différemment exprimés entre les 2 types considérés ce qui constitue une approche plus conservatrice que la p-valeur sans ajustement où 3 480 gènes ont été estimés différemment exprimés, mais qui garde quand même un nombre suffisant de gènes. La figure 3 ci-dessous, nous montre la différence entre la p-valeur ajustée en utilisant fdr et celle sans modification.

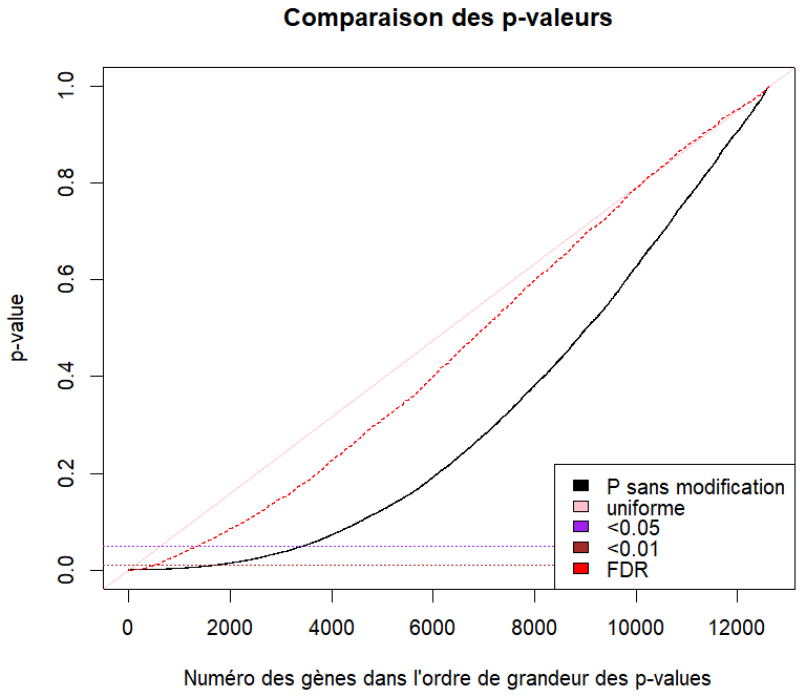


Figure 3: Comparaison des p-valeurs obtenue

4.2 Volcano plot des gènes différemment exprimés

La figure 4 présente un volcano plot illustrant les résultats de l'analyse différentielle. Ce graphique permet de visualiser simultanément l'amplitude du changement d'expression

(log2 Fold Change, en abscisse) et la significativité statistique (-log16 de la p-valeur ajustée, en ordonnée) pour chaque gène.

Les gènes situés en haut du graphique sont ceux dont la p-valeur ajustée est la plus faible, donc les plus significatifs statistiquement. Ceux situés sur les côtés extrêmes de l'axe des abscisses ont une variation d'expression plus importante entre les deux groupes.

Les points ont été colorés selon les critères suivants : les gènes ayant un log2 Fold Change supérieur à 1 en valeur absolue mais une faible significativité apparaissent en bleu. Ceux avec une p-valeur très significative mais un faible Fold Change en valeur absolue apparaissent en vert. Enfin, les gènes qui combinent une forte significativité et un changement d'expression important sont en rouge. Nous remarquons que le volcano plot est en adéquation avec les résultats précédents, nous remarquons qu'il y a très peu de gènes fortement différemment exprimés environ 50.

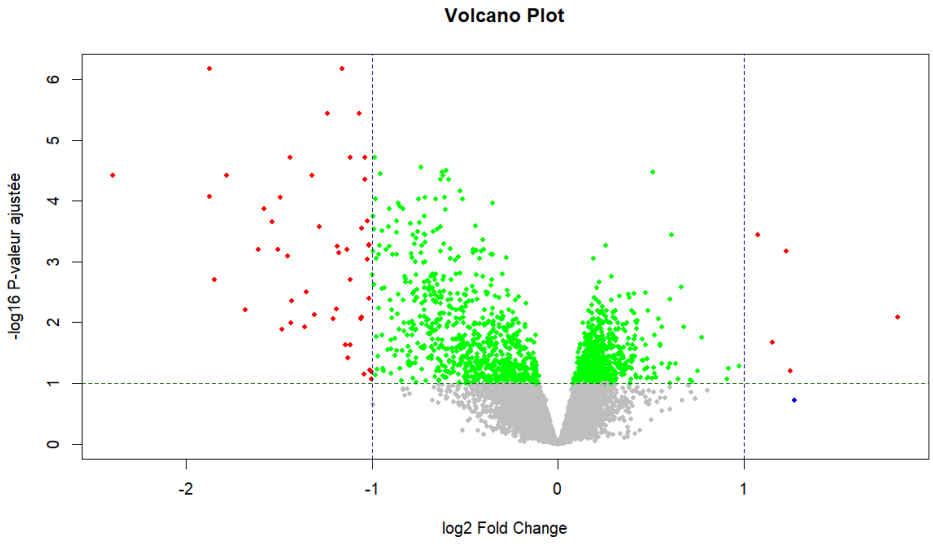


Figure 4: Volcano plot représentant les gènes en fonction du log2 Fold Change et de la significativité statistique.

Enfin, la table 2, à la fin du document, contient les 50 gènes les plus différemment exprimés, classés selon la valeur des p-valeurs ajustées obtenues

5 Analyse de cluster des données hyperdiploïdes

Afin d'explorer la structure des échantillons hyperdiploïdes, une analyse de clustering a été réalisée. Nous avons tout d'abord extrait les données d'expression des 22 échantillons hyperdiploïdes, puis calculé une matrice de corrélation entre ces échantillons. La dissimilarité (définie comme $1 - \text{corrélation}$) a été utilisée comme mesure de distance pour effectuer un clustering hiérarchique, selon la méthode d'agglomération moyenne.

La carte de chaleur des similarités inter-échantillons, obtenue à l'aide de la même distance et méthode (Figure 5), révèle la présence de plusieurs groupes d'échantillons fortement corrélés entre eux. Visuellement, entre deux et cinq groupes semblent émerger.

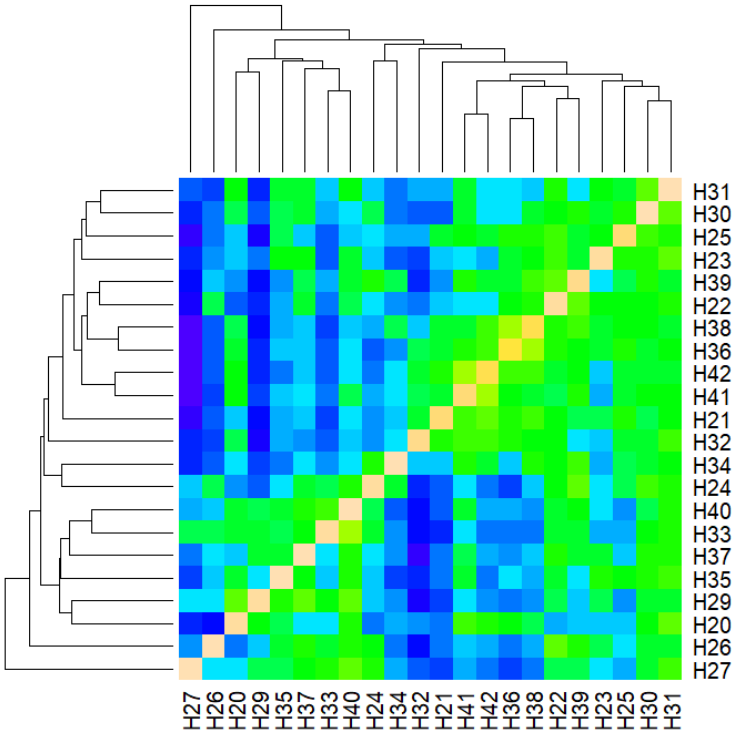


Figure 5: Carte de chaleur des corrélations entre les échantillons hyperdiploïdes. Les couleurs indiquent le degré de similarité : plus la couleur est chaude (jaune), plus la corrélation entre deux échantillons est forte ; plus elle est froide (bleu foncé), plus la corrélation est faible.

Sur cette base, nous avons appliqué la méthode des k-means qui fonctionne de la manière suivante: étant donné un nombre de clusters prédéfini (en l'occurence k) l'algorithme répartit les échantillons en k groupes en minimisant la distance intra-cluster. Il commence par initialiser aléatoirement k centres, puis affecte chaque échantillon au centre le plus proche. Ensuite, il recalcule les centres comme la moyenne des points assignés à chaque cluster, et réitère ces deux étapes jusqu'à convergence. Nous avons à nouveau utilisé la dissimilarité comme mesure de distance. Comme nous ne connaissons pas le nombre optimal de clusters, nous avons évalué différentes solutions allant de $k = 2$ à $k = 7$, à l'aide de deux indicateurs de performance : la largeur moyenne de silhouette et l'indice de Dunn.

La Figure 6 ci-dessous, montre que la solution à 2 clusters est la seule à présenter une largeur de silhouette moyenne proche de 0,25, ce qui suggère une structure faiblement définie. Pour des valeurs de k supérieures, la silhouette devient très faible, indiquant des partitions peu cohérentes. L'indice de Dunn reste relativement stable entre les différentes valeurs de k. Ainsi, en nous appuyant sur ces deux indicateurs, nous avons retenu la solution à 2 clusters comme étant la plus pertinente, mais comme vu précédemment, la structure des groupes reste modérément définie, ce qui invite à une interprétation prudente des résultats de partitionnement. Les affectations des échantillons aux deux groupes sont présentées dans la Table 1 ci-dessous.

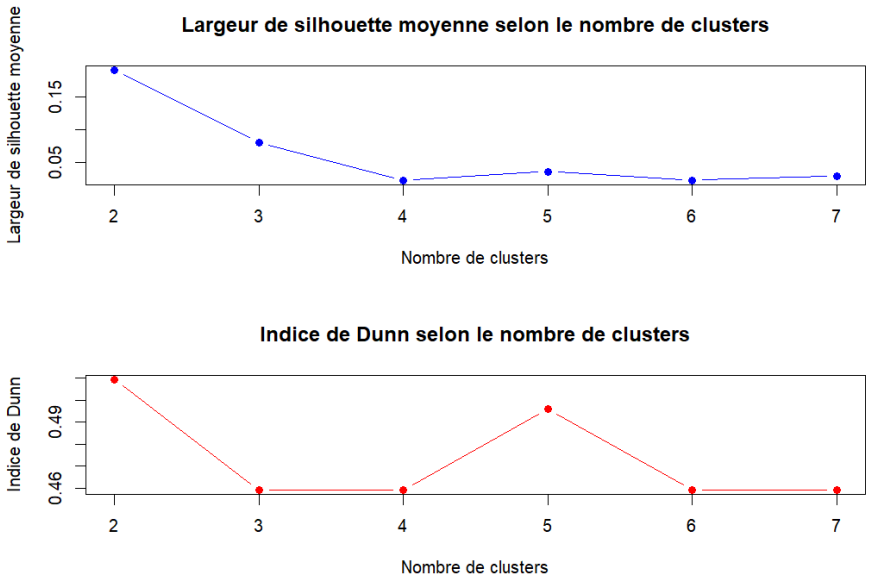


Figure 6: Évolution de la largeur de silhouette moyenne (en bleu) et de l'indice de Dunn (en rouge) selon le nombre de clusters considérés.

Cluster	**Échantillons**
1	H20, H22, H23, H24, H26, H27, H29, H30, H31, H33, H35, H37, H39, H40
2	H21, H25, H32, H34, H36, H38, H41, H42

Table 1: Répartition des échantillons hyperdiploïdes par cluster

6 Conclusion

Cette étude a permis de mettre en évidence des différences significatives d'expression génique entre les cas de leucémies lymphoblastiques aiguës pédiatriques hyperdiploïdes et les échantillons de référence sans anomalie cytogénétique récurrente. Grâce à une démarche rigoureuse intégrant un prétraitement par normalisation RMA, une modélisation statistique via le package `limma`, et une correction des p-valeurs par la méthode de Benjamini-Hochberg, nous avons identifié 1 355 gènes exprimés de manières significativements différentes. Parmi eux, environ 50 gènes présentent à la fois une forte significativité statistique et une variation marquée d'expression, ce qui en fait des candidats potentiels pour de futures études fonctionnelles.

L'analyse de clustering des échantillons hyperdiploïdes a permis d'identifier deux groupes distincts. Même si cette séparation reste modérée d'un point de vue statistique, elle suggère qu'il pourrait exister des différences importantes entre ces deux groupes. Cela montre qu'il n'est peut-être pas pertinent de considérer tous les cas hyperdiploïdes comme identiques, et qu'il serait utile d'examiner de plus près les variations possibles au sein de cette catégorie.

En résumé, notre étude aide à mieux comprendre les spécificités des cas d'hyperdiploïdie dans la leucémie pédiatrique. Elle met en évidence des éléments qui pourraient, à l'avenir, aider à améliorer le diagnostic ou le suivi de la maladie.

	Log2FC	Moyenne	Stat t	p-valeur	p-fdr	Score B
38968_at	-1.87	8.65	-9.33	4.88e-12	3.73e-08	17.05
38518_at	-1.16	6.26	-9.24	5.91e-12	3.73e-08	16.87
37350_at	-1.24	7.34	-8.47	6.78e-11	2.84e-07	14.59
38336_at	-1.07	5.64	-8.45	8.99e-11	2.84e-07	14.32
38738_at	-1.04	8.42	-7.63	1.07e-09	2.13e-06	11.99
306_s_at	-1.12	9.55	-7.62	1.11e-09	2.13e-06	11.96
38869_at	-0.99	5.12	-7.70	1.23e-09	2.13e-06	11.87
32207_at	-1.44	7.73	-7.64	1.35e-09	2.13e-06	11.78
32251_at	-0.74	5.28	-7.41	2.38e-09	3.34e-06	11.24
34223_at	-0.60	5.98	-7.32	3.06e-09	3.86e-06	11.00
35170_at	0.51	6.11	7.27	3.69e-09	4.17e-06	10.82
38317_at	-0.62	5.91	-7.25	3.96e-09	4.17e-06	10.75
36107_at	-0.96	5.68	-7.28	4.50e-09	4.37e-06	10.64
38604_at	-2.39	7.68	-7.36	5.27e-09	4.71e-06	10.51
39402_at	-1.32	7.77	-7.21	5.60e-09	4.71e-06	10.44
35688_g_at	-0.62	5.38	-7.11	6.40e-09	4.80e-06	10.30
36620_at	-1.78	7.88	-7.23	6.47e-09	4.80e-06	10.31
41132_r_at	-0.59	4.96	-7.03	8.31e-09	5.76e-06	10.05
40903_at	-0.63	5.47	-7.01	9.09e-09	5.76e-06	9.97
31863_at	-1.04	6.70	-7.06	9.12e-09	5.76e-06	9.97
38792_at	-0.53	5.83	-6.85	1.59e-08	9.55e-06	9.44
35939_s_at	-1.87	8.13	-6.88	2.16e-08	1.24e-05	9.17
1520_s_at	-1.49	8.29	-6.80	2.40e-08	1.29e-05	9.06
36542_at	-0.71	4.92	-6.77	2.51e-08	1.29e-05	9.02
39721_at	-0.61	7.95	-6.71	2.55e-08	1.29e-05	9.00
596_s_at	-0.75	5.86	-6.67	3.00e-08	1.41e-05	8.84
33399_at	-0.66	5.18	-6.66	3.13e-08	1.41e-05	8.80
38527_at	-0.98	10.07	-6.64	3.23e-08	1.41e-05	8.77
36023_at	-0.52	5.19	-6.64	3.24e-08	1.41e-05	8.77
33746_at	-0.35	5.01	-6.58	4.01e-08	1.69e-05	8.57
37029_at	-0.86	7.68	-6.57	4.15e-08	1.69e-05	8.53
36128_at	-0.85	6.67	-6.53	4.97e-08	1.96e-05	8.37
39714_at	-0.83	6.83	-6.48	5.84e-08	2.18e-05	8.21
36687_at	-0.91	5.44	-6.53	6.01e-08	2.18e-05	8.20
307_at	-1.58	7.40	-6.57	6.05e-08	2.18e-05	8.20
38260_at	-0.60	7.43	-6.44	6.42e-08	2.25e-05	8.12
36921_at	-0.72	5.32	-6.37	9.04e-08	3.05e-05	7.80
35754_at	-1.00	7.43	-6.36	9.20e-08	3.05e-05	7.78
36795_at	-0.87	9.64	-6.27	1.18e-07	3.81e-05	7.54
39345_at	-1.03	6.65	-6.31	1.24e-07	3.90e-05	7.51
39781_at	-1.54	6.63	-6.36	1.30e-07	4.02e-05	7.48
39378_at	-0.74	8.39	-6.22	1.39e-07	4.17e-05	7.39
39767_at	-0.79	7.85	-6.20	1.49e-07	4.36e-05	7.33
31786_at	-0.44	4.50	-6.18	1.69e-07	4.84e-05	7.21
37640_at	-0.91	5.62	-6.21	1.75e-07	4.92e-05	7.18
32236_at	-0.63	6.92	-6.14	1.81e-07	4.94e-05	7.14
37677_at	-1.28	9.41	-6.17	1.84e-07	4.94e-05	7.13
33641_g_at	-1.06	6.19	-6.18	2.04e-07	5.37e-05	7.04
36194_at	-0.65	6.25	-6.09	2.15e-07	5.53e-05	6.98
39980_at	-0.99	6.45	-6.14	2.20e-07	5.55e-05	6.97

Table 2: 50 gènes les plus différemment exprimés basé sur la p-valeur ajustée

References

[1] Eng-Juh Yeoh, Mary E Ross, Sheila A Shurtleff, W.Kent Williams, Divyen Patel, Rami Mahfouz, Fred G Behm, Susana C Raimondi, Mary V Relling, Anami Patel, Cheng Cheng, Dario Campana, Dawn Wilkins, Xiaodong Zhou, Jinyan Li, Huiqing Liu, Ching-Hon Pui, William E Evans, Clayton Naeve, Limsoon Wong, and James R Downing. Classification, subtype discovery, and prediction of outcome in pediatric acute lymphoblastic leukemia by gene expression profiling. *Cancer Cell*, 1(2):133–143, 2002.